

Zadanie Numeryczne 4 – Kacper Drużdżel

- a) Algorytm Gaussa-Seidela
- b) Metoda gradientów sprzężonych

a)

$$x_i^{(k+1)} = \left(b_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^N a_{ij}x_j^{(k)} \right) / a_{ii}$$

W metodzie Gaussa-Seidela rozpatrujemy powyższy wzór.

Algorytm ogólny jest następujący:

```
Wybierz początkowe przybliżenie  $\mathbf{x}^{(0)}$ 
for k := 1 step 1 until oczekiwane przybliżenie do
  for i := 1 step 1 until n do
     $\sigma = 0$ 
    for j := 1 step 1 until i-1 do
       $\sigma = \sigma + a_{ij}x_j^{(k)}$ 
    end (j-for)
    for j := i+1 step 1 until n do
       $\sigma = \sigma + a_{ij}x_j^{(k-1)}$ 
    end (j-for)
     $x_i^{(k)} = \frac{(b_i - \sigma)}{a_{ii}}$ 
  end (i-for)
  sprawdź, czy osiągnięto oczekiwane przybliżenie
end (k-for)
 $\mathbf{x} \approx \mathbf{x}^{(k)}$ 
```

- b) Metoda gradientów sprzężonych

Wykorzystałem algorytm podany na wykładzie

$\mathbf{A} \in \mathbb{R}^{N \times N}$ symetryczna, dodatnio określona, \mathbf{x}_1 — początkowe przybliżenie rozwiązania równania (12), $0 < \varepsilon \ll 1$.

$$\begin{aligned}
 &\mathbf{r}_1 = \mathbf{b} - \mathbf{A}\mathbf{x}_1, \mathbf{p}_1 = \mathbf{r}_1 \\
 &\mathbf{while} \quad \|\mathbf{r}_k\| > \varepsilon \\
 &\quad \alpha_k = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{p}_k^T \mathbf{A} \mathbf{p}_k} \\
 &\quad \mathbf{r}_{k+1} = \mathbf{r}_k - \alpha_k \mathbf{A} \mathbf{p}_k \\
 &\quad \beta_k = \frac{\mathbf{r}_{k+1}^T \mathbf{r}_{k+1}}{\mathbf{r}_k^T \mathbf{r}_k} \\
 &\quad \mathbf{p}_{k+1} = \mathbf{r}_{k+1} + \beta_k \mathbf{p}_k \\
 &\quad \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{p}_k \\
 &\mathbf{end}
 \end{aligned} \tag{13}$$

Z każdą iteracją wynik staje się dokładniejszy.

Uruchomienie programów:

G++ -o zad4a zad4a.cpp

G++ -o zad4b zad4b.cpp

Następnie:

./zad4a

./zad4b